

Evid Accuracy

One-hop

	10K	20K	30K	40K	50K	100K	200K	300K	400K	500K	600K	700K	1M
GPT-4o	75	88	81	88	69	88	62	69	56	62	N/A	N/A	N/A
GPT-4.1	100	100	94	100	100	100	100	100	81	94	94	94	81
O3-mini	81	81	88	88	81	75	69	44	38	31	25	19	N/A
GPT-5	100	100	100	100	100	100	100	100	100	100	100	100	94
Sonnet-4	100	100	100	100	100	94	94	94	94	88	88	69	N/A
Sonnet-4.5	100	100	100	94	100	94	100	88	88	69	88	62	N/A
Gemini-2.5-Fl	100	100	100	100	100	100	100	100	88	94	81	81	94
Gemini-3-Fl	100	100	100	100	100	100	100	100	100	100	100	100	100

Two-hop

	10K	20K	30K	40K	50K	100K	200K	300K	400K	500K	600K	700K	1M
GPT-4o	69	81	87	75	69	56	44	31	44	62	N/A	N/A	N/A
GPT-4.1	100	94	94	100	100	94	100	100	88	81	81	88	62
O3-mini	69	69	69	56	69	50	56	38	44	38	25	12	N/A
GPT-5	88	94	94	94	94	87	100	100	94	93	94	93	81
Sonnet-4	88	88	81	94	81	88	69	62	56	56	81	50	N/A
Sonnet-4.5	100	100	94	94	100	88	75	62	69	50	75	38	N/A
Gemini-2.5-Fl	94	81	88	75	62	50	56	56	56	31	25	25	31
Gemini-3-Fl	69	75	80	93	93	94	94	94	93	100	94	94	93

Evid Accuracy (%)